

Тема: Детекција на когнитивен замор со нискоканален EEG

1. Цел на проектот и податочно множество

Целта на проектот е да се истражи можноста за автоматска детекција на когнитивен замор при долготрајно возење со користење мал број EEG-канали. Намалувањето на бројот на канали е важно за развој на поедноставен и практичен носив EEG-уред.

За реализација на проектот беше употребено јавно достапното податочно множество Multimodal Phenotyping Dataset of Driving Fatigue – MPD-DF. Податоците се преземени од официјалното складиште Figshare, article ID 28455737, со DOI 10.6084/m9.figshare.28455737.v2. Податочното множество е достапно под лиценца CC BY 4.0.

Во проектот беа употребени податоците од првите 30 испитаници. За секој испитаник беа преземени само суровиот EEG-запис во EDF-формат и текстуалната датотека со временските анотации. Другите модалитети, како ECG, EOG, respiration, видео и прашалници, не беа користени.

Оригиналните анотации беа претворени во бинарна класификација:

- 0 – будна, односно alert состојба;
- 1 – замор, при што оригиналните нивоа 1–4 беа обединети во една fatigue класа.

2. Претпроцесирање на EEG-сигналите

За EEGNet беа избрани каналите C3, C4, O1 и O2. Оригиналната фреквенција на семплирање од 500 Hz беше намалена на 128 Hz, а сигналите беа филтрирани со band-pass филтер од 0.5 до 40 Hz.

Сигналите беа поделени на прозорци од пет секунди без преклопување. Еден четириканален прозорец има форма 4×640 примероци. Не беше дозволено еден прозорец да преминува преку промена на анотацијата. Прозорците со peak-to-peak амплитуда поголема од 200 μV беа означени како можни артефакти, но не беа автоматски избришани.

По претпроцесирањето беа добиени вкупно 43.620 EEG-прозорци, од кои:

- 33.825 прозорци со alert состојба;
- 9.795 прозорци со fatigue состојба;
- 2.807 прозорци означени како можни артефакти.

Поради нерамномерната застапеност на класите, главна метрика беше balanced accuracy, а дополнително беа користени sensitivity, specificity, F1-score и ROC AUC.

3. Обучени модели и евалуација

Најпрво беа обучени два класични baseline модели: **Logistic Regression** и **Random Forest**. Овие модели користат претходно извлечени фреквентни EEG-карактеристики, меѓу кои моќноста во delta, theta, alpha и beta опсезите и нивните соодноси.

Потоа беше обучен **EEGNet**, компактна convolutional neural network создадена за обработка на EEG-сигнали. Беа испитани три конфигурации:

1. само O1;
2. O1 и O2;
3. C3, C4, O1 и O2.

Baseline моделите и EEGNet беа оценети со **Leave-One-Subject-Out – LOSO** евалуација. Во секој од 30 folds, еден испитаник целосно се користи за тестирање, додека останатите испитаници се користат за развој на моделот. Со ова се избегнува subject leakage и се проверува способноста на моделот да генерализира на ново лице.

Најсоодветна EEGNet конфигурација беше моделот со само O1 канал. Тој постигна balanced accuracy од **0.655**, sensitivity од **0.528**, specificity од **0.797**, F1-score од **0.343** и ROC AUC од **0.758**. Иако Logistic Regression со O1 имаше минимално повисока balanced accuracy од 0.658, EEGNet имаше подобри sensitivity и ROC AUC. Резултатите покажаа дека додавањето дополнителни EEG-каналы не донесе подобрување.

Како последен модел беше употребен **LaBraM**, pretrained foundation model за EEG. За него беше направено посебно претпроцесирање: семплирање на 200 Hz, band-pass филтер од 0.1 до 75 Hz, notch-филтер на 50 Hz и петсекундни прозорци во μV . Беше користен само каналот O1.

Официјалниот pretrained LaBraM-base модел беше дополнително обучен, односно fine-tuned, со следната subject-independent поделба:

- испитаници 01–24 за training;
- испитаници 25–27 за validation;
- испитаници 28–30 за финално тестирање.

LaBraM постигна balanced accuracy од **0.737**, sensitivity од **0.561**, specificity од **0.913**, F1-score од **0.498** и ROC AUC од **0.793**. Најдобриот модел беше добиен во втората епоха.

4. Резултати

	Balanced accuracy	Sensitivity	Specificity	F1-score	ROC AUC
Logistic Regression · O1	0.658	0.522	0.807	0.341	0.722
Random Forest · O1	0.655	0.387	0.933	0.344	0.693
Logistic Regression · O1/O2	0.654	0.513	0.808	0.333	0.717
Random Forest · O1/O2	0.654	0.377	0.940	0.344	0.682
Logistic Regression · 4 канали	0.649	0.498	0.810	0.340	0.730
Random Forest · 4 канали	0.655	0.364	0.954 ★	0.350	0.714
EEGNet · O1	0.655	0.528	0.797	0.343	0.758
EEGNet · O1/O2	0.636	0.502	0.786	0.328	0.727
EEGNet · 4 канали	0.649	0.472	0.843	0.305	0.747
Foundation model LaBraM · O1	0.737 ★	0.561 ★	0.913	0.498 ★	0.793 ★

5. Заклучок

Резултатите покажуваат дека когнитивниот замор може да се детектира со само еден окципитален EEG-канал, O1. Ова е значајно бидејќи едноканалната конфигурација е поедноставна, поудобна и посоодветна за иден носив уред.

Pretrained LaBraM моделот покажа подобри забележани резултати од EEGNet и од класичните модели. Сепак, системот сè уште не е подготвен за практична безбедносна или медицинска употреба. Потребни се дополнителна валидација со повеќе испитаници, LOSO евалуација на LaBraM и тестирање со EEG-сигнали собрани во реални услови.

Изработи :

Марија Белеска - 221081

За целите на предметот Имплементација на системи со слободен и отворен код